


Extracción de conocimiento de
Bases de Datos

Evidencias unidad 2

Diego Ricardo Amador Casillas 9A IDGS

5 de Julio del 2026



```
Problems Output Debug Console Terminal Ports
C:\Users\amado\Downloads\examen_etl>cd unidad2_etl_biblioteca

C:\Users\amado\Downloads\examen_etl\unidad2_etl_biblioteca>cd scripts

C:\Users\amado\Downloads\examen_etl\unidad2_etl_biblioteca\scripts>python etl_biblioteca.py
Iniciando proceso ETL...
Base de datos establecida exitosamente.
-----
Filas leídas: 100
Filas cargadas: 98
Filas rechazadas: 2
Estado: FINALIZADO_CON_ERRORES
-----
Reporte de ejecución guardado con éxito.

C:\Users\amado\Downloads\examen_etl\unidad2_etl_biblioteca\scripts>
```



```

1 • create database biblioteca_dw;
2 • use biblioteca_dw;
3
4 • select * from fact_prestamos;
5 • select * from etl_errores;
6 • select * from etl_log;
7
8 -- 1. Cuantos registros hay en 'fact_prestamos'.

```

id_prestamo	id_fecha	id_alumno	id_carrera	id_libro	id_sede	dias_prestamo	multa_diaria	total_multa
5001	1	1	1	1	1	3	0.00	0.00
5002	2	2	2	2	2	5	5.00	25.00
5003	3	3	3	3	3	7	10.00	70.00
5004	4	4	4	4	4	2	15.00	30.00
5005	5	5	5	5	1	4	0.00	0.00
5006	6	6	1	6	2	6	5.00	30.00
5007	7	7	2	7	3	8	10.00	80.00
5008	8	8	3	8	4	1	15.00	15.00
5009	9	9	4	9	1	9	0.00	0.00
5010	10	10	5	10	2	10	5.00	50.00
5011	11	11	1	1	3	3	10.00	30.00
5012	12	12	2	2	4	5	15.00	75.00
5013	13	13	3	3	1	7	0.00	0.00
5014	14	14	4	4	2	2	5.00	10.00
5015	15	15	5	5	3	4	10.00	40.00
5016	16	16	1	6	4	6	15.00	90.00

```

4 • select * from fact_prestamos;
5 • select * from etl_errores;
6 • select * from etl_log;
7
8 -- 1. Cuantos registros hay en 'fact_prestamos'.

```

id_error	fecha_error	archivo_origen	fila_csv	id_registro	descripcion_error	datos_originales
1	2026-07-05 22:57:25	prestamos_biblioteca_100.csv	100	5099	total_multa incorrecto para el id_prestamo 5099	('id_prestamo': 5099, 'fecha_prestamo': dateti...
2	2026-07-05 22:57:25	prestamos_biblioteca_100.csv	101	5002	id_prestamo 5002 duplicado	('id_prestamo': 5002, 'fecha_prestamo': dateti...

Result Grid							
Filter Rows:							
	id_log	fecha_ejecucion	archivo_origen	filas_leidas	filas_cargadas	filas_rechazadas	estado
▶	1	2026-07-05 22:57:25	prestamos_biblioteca_100.csv	100	98	2	FINALIZADO_CON_ERRORES
•	NULL	NULL	NULL	NULL	NULL	NULL	NULL

fact_prestamos 1 etl_errores 2 etl_log 3 x

```

8      -- 1. Cuantos registros hay en `fact_prestamos`.
9 •    SELECT COUNT(*) AS total_fact_prestamos FROM fact_prestamos;
10
11     -- 2. Cuantos registros hay en `etl_errores`.
12 •    SELECT COUNT(*) AS total_etl_errores FROM etl_errores;

```

Result Grid	
Filter Rows:	
	total_fact_prestamos
▶	98

```

11     -- 2. Cuantos registros hay en `etl_errores`.
12 •    SELECT COUNT(*) AS total_etl_errores FROM etl_errores;
13

```

Result Grid	
Filter Rows:	
	total_etl_errores
▶	2

```

14 -- 3. Que errores fueron registrados.
15 • SELECT id_registro, descripcion_error, archivo_origen FROM etl_errores;
16
17 -- 4. Cual fue el último estado registrado en `etl_log`.

```

Result Grid	Filter Rows:	Export:	Wrap Cell Content:
id_registro	descripcion_error	archivo_origen	
5099	total_multa incorrecto para el id_prestamo 5099	prestamos_biblioteca_100.csv	
5002	id_prestamo 5002 duplicado	prestamos_biblioteca_100.csv	

```

17 -- 4. Cual fue el último estado registrado en `etl_log`.
18 • SELECT estado, fecha_ejecucion FROM etl_log ORDER BY id_log DESC LIMIT 1;
19
20 -- 5. Total de multas por carrera.
21 • SELECT c.carrera, SUM(f.total_multa) AS suma_multas

```

Result Grid	Filter Rows:	Export:	Wrap Cell Content:
estado	fecha_ejecucion		
FINALIZADO_CON_ERRORES	2026-07-05 22:57:25		

```

--
20 -- 5. Total de multas por carrera.
21 • SELECT c.carrera, SUM(f.total_multa) AS suma_multas
22 FROM fact_prestamos f
23 JOIN dim_carrera c ON f.id_carrera = c.id_carrera
24 GROUP BY c.carrera;
25
26 -- 6. Total de multas por categoria de libro.

```

Result Grid	Filter Rows:	Export:	Wrap Cell Content:
carrera	suma_multas		
DNAM	1050.00		
IDGS	750.00		
IGE	450.00		
IRD	900.00		
ITI	560.00		

```

26 -- 6. Total de multas por categoria de libro.
27 • SELECT l.categoria, SUM(f.total_multa) AS suma_multas
28 FROM fact_prestamos f
29 JOIN dim_libro l ON f.id_libro = l.id_libro
30 GROUP BY l.categoria;
31
32 -- 7. Promedio de dias de prestamo por sede.
33 • SELECT s.sede, AVG(f.dias_prestamo) AS promedio_dias

```

Result Grid |  Filter Rows: | Export:  | Wrap Cell Contents: 

	categoria	suma_multas
▶	Analitica	710.00
	Bases de datos	600.00
	Matematicas	600.00
	Inteligencia artificial	850.00
	Software	200.00
	Sistemas	400.00
	Programacion	150.00
	Redes	200.00

```

32 -- 7. Promedio de dias de prestamo por sede.
33 • SELECT s.sede, AVG(f.dias_prestamo) AS promedio_dias
34 FROM fact_prestamos f
35 JOIN dim_sede s ON f.id_sede = s.id_sede
36 GROUP BY s.sede;
37

```

Result Grid |  Filter Rows: | Export:  | Wrap Cell Contents: 

	sede	promedio_dias
▶	Biblioteca Central	6.2000
	Laboratorio Digital	4.5833
	Sala Norte	4.8000
	Sala Sur	6.0833

```

38 -- 8. Los 5 libros con mayor total de multa.
39 • SELECT l.libro, SUM(f.total_multa) AS total_multa_generada
40 FROM fact_prestamos f
41 JOIN dim_libro l ON f.id_libro = l.id_libro
42 GROUP BY l.libro
43 ORDER BY total_multa_generada DESC
44 LIMIT 5;
45

```

Result Grid		Filter Rows:	Export:	Wrap Cell Content:
	libro	total_multa_generada		
►	Fundamentos de IA	850.00		
	Estadística Aplicada	600.00		
	Bases de Datos I	500.00		
	Linux para Todos	400.00		
	Análisis de Datos	360.00		

```

46 -- 9. Prestamos detallados con fecha, alumno, carrera, libro, categoria, sede y total de multa.
47 • SELECT
48     fe.fecha,
49     a.alumno,
50     c.carrera,
51     l.libro,

```

fecha	alumno	carrera	libro	categoria	sede	total_multa
2026-06-01	Ana Lopez	IDGS	Python Basico	Programacion	Biblioteca Central	0.00
2026-06-02	Luis Perez	IRD	Bases de Datos I	Bases de datos	Sala Norte	25.00
2026-06-03	Sofia Ruiz	IGE	Mineria de Datos	Analitica	Sala Sur	70.00
2026-06-04	Pedro Mata	ITI	Redes de Computadoras	Redes	Laboratorio Digital	30.00
2026-06-05	Laura Diaz	DNAM	Ingenieria de Software	Software	Biblioteca Central	0.00
2026-06-06	Carlos Luna	IDGS	Estadistica Aplicada	Matematicas	Sala Norte	30.00
2026-06-07	Maria Solis	IRD	Linux para Todos	Sistemas	Sala Sur	80.00
2026-06-08	Jorge Cano	IGE	SQL Practico	Bases de datos	Laboratorio Digital	15.00
2026-06-09	Daniel Torres	ITI	Analisis de Datos	Analitica	Biblioteca Central	0.00
2026-06-10	Paola Reyes	DNAM	Fundamentos de IA	Inteligencia artificial	Sala Norte	50.00
2026-06-11	Roberto Silva	IDGS	Python Basico	Programacion	Sala Sur	30.00
2026-06-12	Alejandra M...	IRD	Bases de Datos I	Bases de datos	Laboratorio Digital	75.00
2026-06-13	Fernanda Rios	IGE	Mineria de Datos	Analitica	Biblioteca Central	0.00
2026-06-14	Miguel Angel	ITI	Redes de Computadoras	Redes	Sala Norte	10.00
2026-06-15	Diana Castillo	DNAM	Ingenieria de Software	Software	Sala Sur	40.00
2026-06-16	Raul Ortega	IDGS	Estadistica Aplicada	Matematicas	Laboratorio Digital	90.00
2026-06-17	Melania Gu...	IRD	Linux para Todos	Sistemas	Biblioteca Central	0.00

Result 12 x

```

63 -- 10. Conteo de prestamos por sede.
64 • SELECT s.sede, COUNT(f.id_prestamo) AS cantidad_prestamos
65 FROM fact_prestamos f
66 JOIN dim_sede s ON f.id_sede = s.id_sede
67 GROUP BY s.sede;
68

```

sede	cantidad_prestamos
Biblioteca Central	25
Laboratorio Digital	24
Sala Norte	25
Sala Sur	24

EL proceso ETL se divide en tres pasos para garantizar que los datos que entran a nuestra base de datos sean confiables y útiles:



Extracción: Primero, tomamos nuestro archivo CSV origen y lo leemos usando la librería pandas en Python. Los datos crudos pasan a la memoria del script listos para ser trabajados.

Transformación:

Estandarizamos el formato: pasamos los nombres de las columnas a minúsculas, quitamos espacios accidentales al inicio o final de los textos y nos aseguramos de que las fechas y los números tengan el tipo de dato correcto.

Aplicamos nuestras reglas de negocio: Revisamos fila por fila que no existan IDs de préstamo duplicados (dejando pasar solo el primero) y comprobamos que el cálculo de la multa sea correcto (días de préstamo * multa diaria).

Carga: Una vez que sabemos qué datos son válidos y cuáles no, los guardamos en MySQL.

Los registros que fallen las validaciones se mandan a una tabla especial llamada etl_errores para poder auditarlos después.

Los registros limpios y correctos se insertan primero en nuestras tablas de "dimensiones" (dim_alumno, dim_libro, etc) cuidando de no duplicar catálogos, y finalmente se guardan en nuestra tabla principal de hechos (fact_prestamos).

Para terminar, registramos un resumen de todo lo que pasó (cuántos leímos, cargamos y rechazamos) en nuestra bitácora etl_log y generamos un reporte de texto.